


一、神经网络

1、神经元概述

神经网络是由一个个的被称为“神经元”的基本单元构成，单个神经元的结构如下图所示：



对于上述的神经元，其输入为 x_1, x_2, x_3 以及截距+1，其输出为：

$$h_{\mathbf{W},b}(\mathbf{x}) = f(\mathbf{W}^T \mathbf{x}) = f\left(\sum_{i=1}^3 W_i x_i + b\right)$$


其中， \mathbf{W} 表示的是向量，代表的是权重，函数 f 称为激活函数，通常激活函数可以选择为Sigmoid函数，或者tanh双曲正切函数，其中，Sigmoid函数

$$f(z) = \frac{1}{1 + e^{-z}}$$

双曲正切函数的形式为：

$$f(z) = \tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$$

以下分别是Sigmoid函数和tanh函数的图像，左边为Sigmoid函数的图像，右边为tanh函数的图像：




Sigmoid函数的区间为 $[0, 1]$ ，而tanh函数的区间为 $[-1, 1]$ 。

若是使用sigmoid作为神经元的激活函数，则当神经元的输出为1时表示该神经元被激活，否则称为未被激活。同样，对于激活函数是tanh时，神经元表示该神经元被激活，否则称为未被激活。

2、神经网络

2.1、神经网络的结构

神经网络是由很多的神经元联结而成的，一个简单的神经网络的结构如下图所示：



其中一个神经元的输出是另一个神经元的输入，+1项表示的是偏置项。上图是含有一个隐含层的神经网络模型， L_1 层称为输入层， L_2 层称为隐含层， L_3 层称为输出层。

2.2、神经网络中的参数说明

在神经网络中，主要有如下的一些参数标识：

- 网络的层数 n_l 。在上述的神经网络中 $n_l = 3$ ，将第 l 层记为 L_l ，则上述的神经网络，输入层为 L_1 ，输出层为 L_3 。
- 网络权重和偏置 $(\mathbf{W}, \mathbf{b}) = (\mathbf{W}^{(1)}, \mathbf{b}^{(1)}, \mathbf{W}^{(2)}, \mathbf{b}^{(2)})$ ，其中 $W_{ij}^{(l)}$ 表示的是第 l 层的第 j 个神经元和第 $l+1$ 层的第 i 个神经元之间的连接参数， $b_i^{(l)}$ 表示的是第 l 层的第 i 个神经元的偏置项。在上图中， $\mathbf{W}^{(1)} \in \mathbb{R}^{3 \times 3}$ ， $\mathbf{W}^{(2)} \in \mathbb{R}^{1 \times 3}$ 。

2.3、神经网络的计算

在神经网络中，一个神经元的输出是另一个神经元的输入。假设 $z_i^{(l)}$ 表示的是第 l 层的第 i 个神经元的输入，假设 $a_i^{(l)}$ 表示的是第 l 层的第 i 个神经元的输出。当 $l=1$ 时， $a_i^{(1)} = x_i$ 。根据上述的神经网络中的权重和偏置，就可以计算神经网络中每一个神经元的输出，从而计算出神经网络的最终的输出 $h_{\mathbf{W},\mathbf{b}}$ 。

对于上述的神经网络结构，有下述的计算：

$$\begin{aligned} z_1^{(2)} &= W_{11}^{(1)} x_1 + W_{12}^{(1)} x_2 + W_{13}^{(1)} x_3 + b_1^{(1)} \\ a_1^{(2)} &= f \left(W_{11}^{(1)} x_1 + W_{12}^{(1)} x_2 + W_{13}^{(1)} x_3 + b_1^{(1)} \right) \\ z_2^{(2)} &= W_{21}^{(1)} x_1 + W_{22}^{(1)} x_2 + W_{23}^{(1)} x_3 + b_2^{(1)} \\ a_2^{(2)} &= f \left(W_{21}^{(1)} x_1 + W_{22}^{(1)} x_2 + W_{23}^{(1)} x_3 + b_2^{(1)} \right) \\ z_3^{(2)} &= W_{31}^{(1)} x_1 + W_{32}^{(1)} x_2 + W_{33}^{(1)} x_3 + b_3^{(1)} \\ a_3^{(2)} &= f \left(W_{31}^{(1)} x_1 + W_{32}^{(1)} x_2 + W_{33}^{(1)} x_3 + b_3^{(1)} \right) \end{aligned}$$


从而，上述神经网络结构的最终的输出结果为：

$$h_{\mathbf{W},\mathbf{b}}(\mathbf{x}) = f \left(W_{11}^{(2)} a_1^{(2)} + W_{12}^{(2)} a_2^{(2)} + W_{13}^{(2)} a_3^{(2)} + b_1^{(2)} \right)$$

上述的步骤称为**前向传播**，指的是信号从输入层，经过每一个神经元，直到输出神经元的传播过程。

2.4、其他形式的神经网络模型

上述以单隐层神经网络为例介绍了神经网络的基本结构，在神经网络的结构中，可以包含多个隐含层，神经网络的输出神经单元也可以是多个，如下面输出单元的神经网络模型：



2.5、神经网络中参数的求解

对于上述神经网络模型，假设有 m 个训练样本 $\{(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(m)}, y^{(m)})\}$ ，对于一个训练样本 (\mathbf{x}, y) ，其损失函数为：

$$J(\mathbf{W}, \mathbf{b}; \mathbf{x}, y) = \frac{1}{2} \|h_{\mathbf{W}, \mathbf{b}}(\mathbf{x}) - y\|^2$$

为了防止模型的过拟合，在损失函数中会加入正则项，即：

$$J = loss + R$$

其中， $loss$ 表示的是损失函数， R 表示的是正则项。则对于上述的含有 m 个样本的训练集，其损失函数为：

$$J(\mathbf{W}, \mathbf{b}) = \left[\frac{1}{m} \sum_{i=1}^m J(\mathbf{W}, \mathbf{b}; \mathbf{x}^{(i)}, y^{(i)}) \right] + \frac{\lambda}{2} \sum_{l=1}^{n_l-1} \sum_{i=1}^{s_l} \sum_{j=1}^{s_{l+1}} (W_{ij}^{(l)})^2$$

通常，偏置项并不放在正则化中，因为在正则化中放入偏置项只会对神经网络产生很小的影响。

我们的目标是要求得参数 \mathbf{W} 和参数 \mathbf{b} 以使得损失函数 $J(\mathbf{W}, \mathbf{b})$ 达到最小值。首先需要对参数进行随机初始化，即将参数初始化为一个很小的接近0的

参数的初始化有很多不同的策略，基本的是要在0附近的很小的邻域内取得随机值。

在随机初始化参数后，利用**前向传播**得到预测值 $h_{\mathbf{W}, \mathbf{b}}(\mathbf{x})$ ，进而可以得到损失函数，此时需要利用损失函数对其参数进行调整，可以使用梯度下降的降对参数的调整如下：

$$W_{ij}^{(l)} = W_{ij}^{(l)} - \alpha \frac{\partial}{\partial W_{ij}^{(l)}} J(\mathbf{W}, \mathbf{b})$$

$$b_i^{(l)} = b_i^{(l)} - \alpha \frac{\partial}{\partial b_i^{(l)}} J(\mathbf{W}, \mathbf{b})$$

其中， α 称为学习率，在计算参数的更新公式中，需要使用到**反向传播算法**。

而 $\frac{\partial}{\partial W_{ij}^{(l)}} J(\mathbf{W}, \mathbf{b})$ ， $\frac{\partial}{\partial b_i^{(l)}} J(\mathbf{W}, \mathbf{b})$ 的具体形式如下：

$$\begin{aligned} \frac{\partial}{\partial W_{ij}^{(l)}} J(\mathbf{W}, \mathbf{b}) &= \left[\frac{1}{m} \sum_{i=1}^m \frac{\partial}{\partial W_{ij}^{(l)}} J(\mathbf{W}, \mathbf{b}; \mathbf{x}^{(i)}, y^{(i)}) \right] + \lambda W_{ij}^{(l)} \\ \frac{\partial}{\partial b_i^{(l)}} J(\mathbf{W}, \mathbf{b}) &= \frac{1}{m} \sum_{i=1}^m \frac{\partial}{\partial b_i^{(l)}} J(\mathbf{W}, \mathbf{b}; \mathbf{x}^{(i)}, y^{(i)}) \end{aligned}$$

反向传播算法的思路如下：对于给定的训练数据 (\mathbf{x}, y) ，通过**前向传播算法**计算出每一个神经元的输出值，当所有神经元的输出都计算完成后，对每一其“残差”，如第 l 层的神经元 i 的残差可以表示为 $\delta_i^{(l)}$ 。该残差表示的是该神经元对最终的残差产生的影响。这里主要分为两种情况，一是神经元为输出神经元。这里假设 $z_i^{(l)}$ 表示第 l 层上的第 i 个神经元的输入加权和，假设 $a_i^{(l)}$ 表示的是第 l 层上的第 i 个神经元的输出，即 $a_i^{(l)} = f(z_i^{(l)})$ 。

- 对于输出层 n_l 上的神经元 i ，其残差为：

$$\begin{aligned}
\delta_i^{(nl)} &= \frac{\partial}{\partial z_i^{nl}} J(\mathbf{W}, \mathbf{b}; \mathbf{x}, y) \\
&= \frac{\partial}{\partial z_i^{nl}} \frac{1}{2} \|y - h_{\mathbf{W}, \mathbf{b}}(\mathbf{x})\|^2 \\
&= \frac{\partial}{\partial z_i^{nl}} \frac{1}{2} \sum_{i=1}^{s_{nl}} \|y_i - a_i^{nl}\|^2 \\
&= (y_i - a_i^{nl}) \cdot (-1) \cdot \frac{\partial}{\partial z_i^{nl}} a_i^{nl} \\
&= -(y_i - a_i^{nl}) \cdot f'(z_i^{nl})
\end{aligned}$$

-对于非输出层，即对于 $l = n_{l-1}, n_{l-2}, \dots, 2$ 各层，第 l 层的残差的计算方法如下（以第 n_{l-1} 层为例）：

$$\begin{aligned}
\delta_i^{(n_{l-1})} &= \frac{\partial}{\partial z_i^{n_{l-1}}} J(\mathbf{W}, \mathbf{b}; \mathbf{x}, y) \\
&= \frac{\partial}{\partial z_i^{n_{l-1}}} \frac{1}{2} \|y - h_{\mathbf{W}, \mathbf{b}}(\mathbf{x})\|^2 \\
&= \frac{\partial}{\partial z_i^{n_{l-1}}} \frac{1}{2} \sum_{j=1}^{s_{n_{l-1}}} \|y_j - a_j^{n_{l-1}}\|^2 \\
&= \frac{1}{2} \sum_{j=1}^{s_{n_{l-1}}} \frac{\partial}{\partial z_i^{n_{l-1}}} \|y_j - a_j^{n_{l-1}}\|^2 \\
&= \frac{1}{2} \sum_{j=1}^{s_{n_{l-1}}} \frac{\partial}{\partial z_j^{n_{l-1}}} \|y_j - a_j^{n_{l-1}}\|^2 \cdot \frac{\partial}{\partial z_i^{n_{l-1}}} z_j^{n_{l-1}} \\
&= \sum_{j=1}^{s_{n_{l-1}}} \delta_j^{(n_{l-1})} \cdot \frac{\partial}{\partial z_i^{n_{l-1}}} z_j^{n_{l-1}} \\
&= \sum_{j=1}^{s_{n_{l-1}}} \left(\delta_j^{(n_{l-1})} \cdot \frac{\partial}{\partial z_i^{n_{l-1}}} \sum_{k=1}^{s_{n_{l-1}}} f(z_k^{n_{l-1}}) \cdot W_{jk}^{n_{l-1}} \right) \\
&= \sum_{j=1}^{s_{n_{l-1}}} \left(\delta_j^{(n_{l-1})} \cdot W_{ji}^{n_{l-1}} \cdot f'(z_i^{n_{l-1}}) \right) \\
&= \left(\sum_{j=1}^{s_{n_{l-1}}} \delta_j^{(n_{l-1})} \cdot W_{ji}^{n_{l-1}} \right) \cdot f'(z_i^{n_{l-1}})
\end{aligned}$$

因此有：

$$\delta_i^{(l)} = \left(\sum_{j=1}^{s_{l+1}} \delta_j^{(l+1)} \cdot W_{ji}^{(l)} \right) \cdot f'(z_i^{(l)})$$

对于神经网络中的权重和偏置的更新公式为：

$$\begin{aligned}
\frac{\partial}{\partial W_{ij}^{(l)}} J(\mathbf{W}, \mathbf{b}; \mathbf{x}, y) &= a_j^{(l)} \delta_i^{(l+1)} \\
\frac{\partial}{\partial b_i^{(l)}} J(\mathbf{W}, \mathbf{b}; \mathbf{x}, y) &= \delta_i^{(l+1)}
\end{aligned}$$

2.6、神经网络的学习过程

对于神经网络的学习过程，大致分为如下的几步：

- 初始化参数，包括权重、偏置、网络层结构，激活函数等等
- 循环计算
 - 正向传播，计算误差
 - 反向传播，调整参数
- 返回最终的神经网络模型

参考文献

- 1、英文版：[UFLDL Tutorial](#)
- 2、中文版：UFLDL教程